

单座光伏电站 15 分钟级功率预测： 基线对比与机器学习方法评估

徐敏纯 学号 3120260807425

2026 年 10 月 1 日

1 摘要

光伏说停就停，所以电网得预先知道它等会儿发多少电。本文以宁夏某光伏电站 2019 年全年 15 分钟级观测数据（35040 条）为对象，设置「同时刻气象可得」与「仅历史观测可用」两类任务，分别以固定系数公式与 Persistence 为基线，比较线性回归、随机森林与梯度提升树的效果，按时间划分前 70% 训练、后 30% 测试。结果显示：在前者下各模型 MAE 均低于 0.1 kW 且相对基线无实质增益，出力与总辐射近似呈固定比例（约 $P = 0.1255 \text{ GHI}$ ）；在后者下随机森林将 MAE 由 1.5374 kW 降至 0.6681 kW，降幅 56.5%，且增益集中于辐射突变时段（最高 72.5%），而辐射平稳时段反而不及 Persistence 基线。结论是：模型价值取决于天气动态，而非算法复杂度。

2 引言

随着光伏装机容量的快速增长，出力的间歇性与波动性给电网调度带来压力，短时功率预测因此成为新能源并网的必要环节 [1]。已有方法大致分三类：依据辐照度与组件温度推算出力的物理方法、依赖数值天气预报的统计方法，以及以随机森林、梯度提升树为代表的机器学习方法 [2, 4]。其中随机森林因对非线性关系拟合能力强、不易过拟合，在超短期预测中被广泛采用 [5]。

已有研究多默认「预测时刻的气象观测已可获得」。但在缺少实时气象采集条件、或气象数据存在传输延迟的电站，只能依据已经采集到的历史序列外推当前出力。这类约束下 Persistence（直接用上一时刻出力当作当前预测）常作为性能下限，其表现究竟容易被机器学习超出多少、又在哪些天气条件下失效，尚缺乏基于长时段实测数据的细粒度分析。

本文要做的事是：如果拿不到当前的气象数据，还能不能继续进行预测。研究以 2019 年全年、15 分钟粒度的实测数据为样本，在同一数据、同一时间切分下比较上述两类信息可得性，并按晴度、辐射突变强度、光照强度三组维度考察误差分布，再用特征重要性与特征消融解释模型的依赖来源。需要提前说明：本文所用目标列与总辐射近似呈固定比例关系，其是否为独立计量的电表读数尚待数据提供方确认，相关检验见第 4.5 节。

3 数据与方法

3.1 数据说明

本实验采用宁夏光伏电站 2019 年全年、15 分钟粒度的发电与气象观测数据，共 35040 条记录、20 个变量，时间自 2019-01-01 00:15 至 2019-12-31 23:45（含首条至 2020-01-01 00:00 的采样结束时刻）。数据由 Science Data Bank 公开发布（版本 V1，2025 年 5 月 29 日在线发布）[3]，DOI 为 10.57760/sciencedb.25490。主要变量包括：太阳总水平辐射 GHI、直接辐射 DNI、散射辐射 DHI、固定倾角斜面辐射 GTI、气温、云层不透明度、相对湿度、10m 风速、风向、地面气压、露点温度、大气可降水量、降雪深度，以及本文的预测目标——电站交流输出功率（实际功率，单位 kW）。

需要说明的是，该数据集页面未公开电站经纬度、海拔与装机容量，故本文仅报告观测统计量（观测时段内最大瞬时功率 128.0403 kW），不对上述元数据进行推测。

3.2 数据质量检查

数据完整性与物理一致性检查结果如下。全表 35040 行、20 列，任何列均无缺失值；时间戳无重复且严格单调递增，相邻记录间隔恒为 15 分钟；记录总数 35040 恰等于 365×96 ，与 2019 年平年的天数吻合，说明全年不存在缺测或补插造成的缺口。

预测目标「实际功率」的取值范围为 0 至 128.0403 kW，其中 49.1% 的样本取值为 0。这部分零值集中出现在日落后至日出前的无日照时段，属于电站停机的物理状态而非数据缺失，因此本文保留其原值，不做插补，也不计为异常。

物理一致性检查以太阳总水平辐射（GHI）为判据，即要求「无辐射时出力必为 0、出力为 0 时辐射亦为 0」。按此判据筛查，全表违反该约束的样本为 0 条。（过程中曾改以固定倾角辐射 GTI 为判据，初筛出 8 条偏差；复核后确认这 8 条位于日出日落边缘，GHI 与 GTI 因传感器取整存在 1 W/m^2 级别的舍入差，属于正常边界响应而非异常数据，故未据此做任何清洗。）

3.3 实验设定与评估指标

为区分「取得同时刻气象观测」与「仅能取得历史观测」两种实际工况，本文设定两类信息可得性不同的任务。

设定甲（同时刻气象）。特征为预测时刻本身的气象读数，含太阳总水平辐射 GHI、直接辐射 DNI、散射辐射 DHI、固定倾角斜面辐射 GTI、气温、相对湿度、云层不透明度与 10m 风速共 8 项，叠加时刻正余弦编码 hour_sin、hour_cos、doy_sin、doy_cos，合计 12 个特征；目标为同一时刻的电站交流输出功率。

设定乙（仅历史观测）。该设定刻意剔除预测时刻自身的气象读数，只使用此前若干刻钟的观测：上一刻及 2、3、6、12 刻钟前的 GHI，上一刻钟的功率，以及 1、6 刻钟前的气温，再叠加同样的 4 个时刻编码，合计 12 个特征。由于不得使用当前时刻读数，该设定不存在数据泄露，也更贴近「只能拿已采集数据估算当前出力」的场景，是本文重点考察的对象。

两个设定采用同一套时间切分：按时间先后划分，前 70% 样本用于训练、后 30% 用于测试（测试集自 2019-09-13 起），训练与测试之间不打乱样本顺序，以避免相邻时段天气模式跨越切

分边界造成的信息泄露。随机森林与梯度提升树均固定随机种子 `random_state=42`，保证结果可复现。

预测性能用平均绝对误差 MAE、均方根误差 RMSE 与决定系数 R^2 三项指标衡量。另设两条不做学习的朴素基线作对照：设定甲采用由数据拟合的固定系数公式 $P = 0.125498 \text{ GHI}$ ，设定乙采用 Persistence 基线（直接把上一刻钟的功率当作本刻钟的预测值）。

4 结果与分析

本节依次报告总体预测性能、误差在不同天气下的分布、模型究竟依赖哪些特征，以及温度与云量的消融实验，最后给出一项针对数据本身性质的检验。本节所有数字均由 `code/` 目录下的脚本自动生成并写入 `results/`，可复现。

4.1 总体预测性能

表 1: 两种设定下的预测误差对比

设定 & 方法	MAE (kW)	RMSE (kW)	R^2
甲基线	0.0349	0.0737	1.0000
甲线性回归	0.0362	0.0738	1.0000
甲随机森林	0.0378	0.0827	1.0000
甲 GBDT	0.0953	0.1879	0.9999
乙基线	1.5374	2.7803	0.9888
乙线性回归	0.9397	1.6682	0.9960
乙随机森林	0.6681	1.5715	0.9964
乙 GBDT	0.7627	1.6016	0.9963




图 1: 典型日发电功率与辐射的时间序列

先说一个反常结果：表 1 给出两种设定下的全部结果，设定甲中四条曲线的 MAE 落在 0.0349~0.0953 kW 之间，表现最好的反而是不做学习、直接用固定系数公式的基线 (0.0349 kW)，线性回归 0.0362 kW，随机森林 0.0378 kW 比回归还差约 4.4%，梯度提升树最差 (0.0953 kW)。以最大瞬时功率约 128 kW 计，0.03 kW 量级的误差仅相当于满发的 0.03%，学习模型相对该公式几乎没有额外增益。这一反常结果将在第 4.5 节得到解释。

再看设定乙：Persistence 基线 MAE 为 1.5374 kW，随机森林降到 0.6681 kW，降幅 56.5%；线性回归 0.9397 kW，梯度提升树 0.7627 kW。即在拿不到当前辐射时，学习模型是明显有效的，且随机森林优于另外两者。图 1 给出典型日功率与辐射的时间序列，可见两者形状高度重合，这也是设定甲精度异常高的直观来源。

4.2 误差的天气分布 (拓展一)




图 2: 不同天气场景下的模型误差

图 2 共有三栏：左栏按晴度 (DNI/GHI) 分组、中栏按辐射突变强度 ΔGHI 分组、右栏按光照强度 (GHI) 分组，均给出随机森林相对 Persistence 基线的误差降幅。中栏的变化最有信息量：辐射突变 10 W/m^2 以下的一组 (平静, 864 个样本) 随机森林 MAE 为 1.268 kW，反而比 Persistence 的 0.6737 kW 更差，降幅为 -88.2%；突变 $30 \sim 60 \text{ W/m}^2$ 一组 (1698 个样本) 降幅 72.5%，为各组之最；突变超过 60 W/m^2 的狂暴组 (206 个样本) 降幅回落至 44.9%。原因在于辐射本就稳定时，「上一时刻功率」几乎就是当前功率，Persistence 已接近最优，模型再去拟合只会引入额外波动。

右栏按光照强度分组，结果稳定得多：只要辐射有变化，模型表现就好——弱光 ($GHI < 200$, 1728 样本) 降幅 60.2%、中光 ($200 \sim 600$, 2446 样本) 55.1%、强光 (> 600 , 457 样本) 53.3%，三组都稳定优于基线。左栏按晴度分组时，晴天稳定的 2267 个样本 (晴度 > 0.85) 提升最多，高达 63.1%；阴天样本少，提升就小——很阴 (298 样本) 与偏阴 (132 样本) 两组仅约 40%。

4.3 特征重要性 (拓展二)

图 3 同时给出随机森林内置重要性与排列重要性，两套排序高度一致：上一时刻功率 P_{lag1} 居首 (内置 0.753、排列 1.306)，上一刻辐射 GHI_{lag1} 次之 (0.237、0.111)，其余十个特征合计仅 0.01 (内置) 与 0.03 (排列)。这说明设定乙中模型几乎完全依赖「刚刚发生的那一条记录」，与 Persistence 思路相近但做了平滑修正。由此也能解释滞后辐射 GHI_{lag2} 至 lag12 为何重要性虽小却不为零：当辐射突变导致上一时刻功率失效时，这些滞后量成为唯一的补充信息。




图 3: 特征重要性与排列重要性

4.4 温度与云量对预测的影响（补充实验）

表 2: 特征消融实验结果（随机森林）

特征集	特征数	MAE (kW)
甲完整（含温度 + 云量）	12	0.0378
甲只删温度	11	0.0379
甲只删云量	11	0.0378
甲温度云量都删	10	0.0379
乙完整（含温度滞后）	8	0.8093
乙删掉温度滞后	6	0.8352

数据提供方曾提示「本区域天气稳定，温度和云量可不作为预测依据」。本文用一个补充实验对此作定量检验，而不是直接采信。表 2 给出特征消融结果：设定甲中删掉温度（12 个特征减为 11）MAE 由 0.0378 变为 0.0379 kW，再把云量也删掉（共删两个、剩 10 个）仍为 0.0379 kW，变化不足 0.3%；设定乙中删掉温度与气温滞后（8 个特征减为 6）MAE 由 0.8093 升到 0.8352 kW，变化 3.2%。也就是说，在这份数据上移除温度与云量几乎不损失精度，该经验判断成立。

但「不损失精度」并不等于「温度对光伏没有物理影响」。本文另做控制变量检验：把总辐射按每 50 W/m^2 分成 16 个区间，只在区间内部考察温度变化引起的出力变化。16 个区间的温度效应落在 $0.004 \sim 0.038 \text{ kW/}^\circ\text{C}$ 之间，符号为正，平均约 $+0.008 \text{ kW/}^\circ\text{C}$ 。而光伏组件温度每升高 1°C ，理论出力应下降约 $0.3\% \sim 0.4\%$ ，满发 128 kW 时约合 $-0.45 \text{ kW/}^\circ\text{C}$ ，符号与量级都与实测相反。原因是本站高温与强辐射出现在同一时段、二者高度共线，温度效应被辐射效应完全吸收，模型无法把两者分开。因此本文的表述是：在这份数据上温度信息不带来可测增益，而非温度对出力没有物理影响。

4.5 关于目标列性质的检验

设定甲中「固定系数公式反而优于所有机器学习模型」这一反常现象，促使本文对目标列本身作进一步检验。把每条记录的出力与同一时刻总辐射作比值，发现该比值几乎恒定：线性拟




图 4: 控制变量下的温度效应 (左) 与特征消融的 MAE 对比 (右)

合得到 $P \approx 0.125498$ GHI, 残差最大仅 0.486 kW, 比值自身的变异系数只有 0.23%。若这是真实的物理测量, 出力与辐射之间还应保留环境温度引起的温降——按组件温度系数 $-0.35\%/^{\circ}\text{C}$ 估算, 全年约 40°C 的温差应在出力上留下约 14% 的残余波动。实测比值与气温的相关系数仅 0.0038, 残差中找不到温度痕迹; 比值与云层不透明度同样无独立关系。三者共同指向: 目标列很可能是由总辐射按固定系数换算得到的量, 而非独立计量的电表读数。

需要说明的是, 在获得数据提供方书面确认之前, 本文不将目标列当作「实测计量功率」作任何外推结论, 全部实验仅视作「以总辐射为条件的出力重建」。若该列确为换算值, 则设定甲的高精度属于定义上的必然, 其价值在于量化了它与辐射之间的确定性关系; 而设定乙的结论 (随机森林相对 Persistence 提升 56.5%) 因不使用当前时刻读数, 不受该性质影响, 依然成立。

5 结论

本文基于宁夏某光伏电站 2019 年全年、15 分钟粒度的运行数据, 比较了「同时刻气象可得」与「仅历史观测可用」两种条件下光伏短时的出力预测效果, 主要结论有四点:

1. 在可取得同时刻总辐射的条件下, 出力与辐射近似呈固定比例关系 ($P \approx 0.125498$ GHI, 比值变异系数 0.23%), 此时机器学习相对固定系数公式没有实质增益, 说明该任务的信息已被单一辐射量基本穷尽。
2. 在仅能获取历史观测的条件下, 随机森林将 MAE 由 Persistence 基线的 1.5374 kW 降至 0.6681 kW, 下降 56.5%, 这是本文认为实际部署中最有价值的结论。
3. 模型增益高度依赖天气动态, 要看辐射变不变来决定要不要上模型: 辐射突变 $30\sim 60\text{ W/m}^2$ 时降幅达 72.5%, 而辐射平稳 (突变 $< 10\text{ W/m}^2$) 时段 Persistence 反而比模型还准 88.2%。这说明 Persistence 是平稳天气下的天然强基线, 不应被直接忽略, 实际使用时宜按辐射突变强度切换预测策略。
4. 特征重要性由上一时刻功率与上一刻辐射主导 (其余十个特征合计不足 0.02); 温度与云量在消融中贡献小于 0.3%, 但这源于温度效应被辐射效应吸收, 不代表温度对出力没有物理影响。

本文存在三点局限：仅使用单一电站一年的数据；未做超参数搜索，模型参数取库默认值；目标列是否为实测计量值尚未获得数据提供方确认（见第 4.5 节）。后续工作可在多站数据上验证设定乙的提升是否稳定，并尝试在辐射突变临近时引入更长的滚动窗口。

6 参考文献

参考文献

- [1] J. Antonanzas, N. Osorio, R. Escobar, R. Urraca, F. J. Martinez-de Pison, and F. Antonanzas-Torres. Review of photovoltaic power forecasting. *Solar Energy*, 136:78–111, 2016.
- [2] R. H. Inman, H. T. C. Pedro, and C. F. M. Coimbra. Solar forecasting methods for renewable energy integration. *Progress in Energy and Combustion Science*, 39(6):535–576, 2013.
- [3] Rambo. Ningxia 2019 photovoltaic power generation dataset, 2025. 15 分钟粒度, 2019 年全年, 宁夏光伏电站.
- [4] S. Sobri, S. Koohi-Kamali, and N. A. Rahim. Solar photovoltaic generation forecasting methods: a review. *Energy Conversion and Management*, 156:459–497, 2018.
- [5] M. Yang, M. Zhao, D. Liu, M. Ma, and X. Su. Improved random forest method for ultra-short-term prediction of the output power of a photovoltaic cluster. *Frontiers in Energy Research*, 9:749367, 2021.